2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 16

Asserquet, Nehuen

Belmonte, Facundo Damian

Hobiague, Juan Pedro

1. Introducción

Este trabajo analiza la 4.ª Encuesta Nacional de Factores de Riesgo (ENFR 2018) para estudiar cómo se relacionan la alimentación, el nivel socioeconómico y los parámetros cardiovasculares de la población adulta argentina.

1.1 El problema y el conjunto de datos

Las enfermedades no transmisibles (ENT), como la hipertensión, la diabetes y la obesidad, están asociadas a factores de riesgo como la alimentación, la actividad física, el consumo de tabaco y de alcohol. Medir esos factores en la población permite orientar las políticas de prevención y evaluar su impacto.

La ENFR 2018 fue realizada por el INDEC junto con el Ministerio de Salud y Desarrollo Social. Releva a la población de 18 años o más que reside en viviendas particulares de áreas urbanas de 5.000 o más habitantes, mediante un cuestionario digital. Se divide en un bloque hogar y un bloque individual, que se completa en tres pasos:

1. **Paso 1:** cuestionario por autorreporte (alimentación, actividad física, tabaco, hipertensión, entre otros).
2. **Paso 2:** mediciones antropométricas de presión arterial, peso, talla y perímetro de cintura.
3. **Paso 3:** mediciones bioquímicas de glucemia capilar y colesterol total.

La base de usuario tiene 29.224 registros, uno por persona encuestada. Su utilidad es doble: permite monitorear la evolución de los factores de riesgo y las ENT, y ofrece parámetros objetivo y medidos de peso, presión y glucemia.

El grupo eligió como aspecto de interés la alimentación y la nutrición: la ingesta de sal, el consumo de frutas y verduras, las barreras para comer saludable y su relación con el peso corporal y la presión arterial. Las dimensiones consideradas son la calidad alimentaria y el consumo de sal, el nivel socioeconómico y los parámetros cardiovasculares.

1.2 Problemas identificados y tratamiento

- **99 (Ns/Nc).** En consumo_fv, bial01 y bial08 el valor 99 significa "No sabe / No contesta". Se modificó a NaN antes de calcular cualquier estadístico, de modo que todos los nulos de la base tengan el mismo formato.
- **Nulos por diseño de la encuesta.** El 25,7% de las personas (submuestra 0) no tiene ninguna medición física ni glucemia. Dentro de la submuestra 1 faltan además las mediciones físicas en el 23,7% de los casos y la glucemia en el 76,1%. En total, las mediciones físicas faltan en cerca del 44% de la base y la glucemia en el 82%.
- **Tratamiento.** Se clasificó cada grupo de nulos (MCAR o MAR) y se eliminaron las filas con nulos hipótesis por hipótesis, solo en las variables que cada una utiliza, sin imputar valores.
- **Ponderadores.** Los resultados no usan los ponderadores muestrales de la encuesta, por lo que describen a las personas encuestadas.

1.3 Organización del trabajo

El informe se organiza en cuatro secciones. La sección 2 presenta el análisis exploratorio: las dimensiones de la base, las variables seleccionadas, el tratamiento de valores nulos y atípicos, y las observaciones que motivaron las hipótesis. La sección 3 desarrolla seis hipótesis: tres propias (3.1 univariada, 3.3 bivariada y 3.5 multivariada) y tres de la cátedra (3.2 univariada, 3.4 bivariada y 3.6 multivariada). Cada una se presenta con su definición, la estrategia de abordaje y los resultados con su discusión. La sección 4 resume las conclusiones. Todo el código está en una única notebook organizada por secciones, y cada figura o tabla indica la sección donde se calcula.

2. Análisis exploratorio de los datos

La exploración de la ENFR 2018 muestra que el aspecto de interés, alimentación y nutrición, puede estudiarse combinando lo que las personas declaran (alimentación, actividad física) con lo que se midió objetivamente (peso, talla, cintura, presión arterial y glucemia), junto con su nivel socioeconómico. Deja además dos rasgos a tener en cuenta: casi todas las variables cuantitativas medidas están sesgadas a la derecha, y las mediciones físicas faltan en cerca del 44% de las personas.

2.1 Dimensiones y características de la base

La base tiene 29.224 registros, uno por persona encuestada, y 287 variables. Las variables provienen de los tres pasos del bloque individual descritos en la sección 1.1. A ellas se suman el nivel de ingresos del hogar, que proviene del bloque hogar, y las variables demográficas de edad y sexo.

2.2 Aspecto de interés y variables seleccionadas

Se eligió como aspecto de interés la alimentación y la nutrición de los argentinos: la ingesta de sal, el consumo de frutas y verduras, los motivos por los que no se come saludable y su impacto en el peso corporal y la presión arterial. Las dimensiones elegidas son la calidad alimentaria y el consumo de sal, el estado económico, para saber si hay acceso a alimentos saludables, y los parámetros cardiovasculares.

Variable	Descripción	Tipo	Comportamiento	Distribución	Presencia de outliers	Valores nulos
id	Identificador único	Cualitativa nominal	Identifica cada elemento.	Uniforme	No aplica	No
bhch04	Edad en años	Cuantitativa discreta	Tiene como mínimo **‘0’** y como máximo **‘104’**.	Simétrica	No	No
quintil_uc	Nivel de ingresos	Cualitativa ordinal	**Quintil 1:** Familias que vivían con menos de $10.000 a $12.000 pesos por mes en total. Familias que no cubrían la Canasta Básica Total (estaban bajo la línea de pobreza o indigencia de 2018). **Quintil 2:** Hogares con ingresos cercanos a los $12.000 mensuales. **Quintil 3:** Hogares con ingresos cercanos a los $18.000 mensuales. **Quintil 4:** Hogares con ingresos cercanos a los $25.000 mensuales. **Quintil 5:** Hogares con ingresos superiores a los $42.000 y hasta $400.000 pesos mensuales de 2018 (el 20% más acomodado del país).	Uniforme	No aplica	No
promedio_fv_diario	Porciones diarias de frutas y verduras	Cuantitativa continua (Cátedra)	Se mide la cantidad en porciones.Tiene como mínimo **‘0,2’** y como máximo **‘12’**.	Sesgada a la derecha	Si	Si
consumo_fv	Cumple meta OMS de 5 porciones diarias	Cualitativa nominal	**1:** Sí. **2:** No. **99:** Ns/Nc.	Distribución libre	No aplica	Si (Hay un valor auxiliar que toma en cuenta todos los valores nulos).
barreras_fyv	Motivo de no comer frutas/verduras	Cualitativa nominal	**1:** Factores individuales. **2:** Factores del entorno. **3:** Factores económicos. **4:** Come la cantidad que considera adecuada. **5:** Otros.	Distribución libre	No aplica	No
bial01	Agrega sal durante la cocción	Cualitativa nominal	**1:** Si. **2:** No. **99:** Ns/Nc.	Distribución libre	No aplica	Si (Hay un valor auxiliar que toma en cuenta todos los valores nulos).

bial02	Agrega sal a la comida en la mesa sin probar	Cualitativa ordinal	**1:** Siempre o casi siempre. **2:** Raras veces. **3:** Nunca.	Distribución libre	No aplica	No
bial08	Autopercepción de qué tan saludable es su alimentación diaria	Cualitativa ordinal	**1:** Muy saludable. **2:** Bastante saludable. **3:** Poco saludable. **4:** Nada saludable. **99:** Ns/Nc.	Distribución libre	No aplica	Si (Hay un valor auxiliar que toma en cuenta todos los valores nulos).
nivel_actividad_fisica	Nivel global de ejercicio	Cualitativa ordinal (Cátedra)	**1:** Alto. **2:** Medio. **3:** Bajo. **99:** Ns/Nc.	Distribución libre	No aplica	Si (Hay un valor auxiliar que toma en cuenta todos los valores nulos).
bima07	Estatura medida en centímetros	Cuantitativa continua	[Altura en cm. según mediciones antropométricas].	Simétrica	Si	Si
bima10	Peso medido en kilogramos	Cuantitativa continua	[Peso en kg. por mediciones antropométricas]	Sesgada a la derecha	Si	Si
imc_bima	Índice de masa corporal medido	Cuantitativa continua (Cátedra)	Tiene como mínimo **‘10,38’** y como máximo **‘66,67’**.	Sesgada a la derecha	Si	Si
bima13	Perímetro de la cintura en centímetros	Cuantitativa continua (Cátedra)	[Perímetro de cintura en cm. según mediciones antropométricas]	Sesgada a la derecha	Si	Si
promedio_sistolica	Presión arterial sistólica media	Cuantitativa continua (Cátedra)	**Mínimo:** 67 mmHg. **Máximo:** 249 mmHg.	Sesgada a la derecha	Si	Si
bimq05	Glucemia capilar en ayunas	Cuantitativa continua (Cátedra)	Tiene como mínimo **‘20’** y como máximo **‘382’**.	Sesgada a la derecha	Si	Si

Tabla 1: Variables seleccionadas, con su descripción, tipo, comportamiento, distribución, presencia de outliers y nulos.

La variable quintil_uc refleja la capacidad económica y el poder de compra real de los hogares, ajustado por la composición familiar (adulto equivalente). Esto permite evaluar si el costo de las frutas y verduras es una barrera de acceso en los estratos de menores ingresos: el quintil 1 agrupa a hogares que vivían con menos de 10.000 a

12.000 pesos mensuales en 2018 y no cubrían la canasta básica total, mientras que el quintil 5 reúne a los de más de 42.000 pesos.

2.3 Variables brindadas por la cátedra

Debemos trabajar con un bloque de mediciones físicas y dietarias: el consumo de frutas y verduras (promedio_fv_diario), el IMC medido (imc_bima), la presión sistólica (promedio_sistolica), el perímetro de la cintura (bima13), la glucemia capilar en ayunas (bimq05), y la edad y el sexo (bhch04 y bhch03). Son las variables que utilizan las hipótesis de la cátedra (3.4 a 3.6).

2.4 Inicio de análisis en Jupyter

Para la apertura de la base de datos imprimimos el método shape y utilizamos el método head() de la clase DataFrame. El primero nos indica las dimensiones de la base y el segundo nos muestra los primeros 5 registros, los cuales nos sirven para tener un primer vistazo del dataset. Esta info es la que se utilizó para explicar las dimensiones en el punto 2.1.

Por otro lado, para el análisis de los datos trabajamos con el método info() de la misma clase, DataFrame, que nos cuenta la cantidad de registros, el número de columnas, y que además cuenta la cantidad de valores nulos en cada columna y el tipo de dato.

En la Fig. 1 se observa la estructura de la base, según se calcula en la Sección 1.0 del código fuente. Las variables de identificación, edad, ingreso y hábitos declarados están completas, mientras que las mediciones físicas faltan en cerca del 44% de los registros y la glucemia en el 82%.

```
<class 'pandas.DataFrame'>
RangeIndex: 29224 entries, 0 to 29223
Data columns (total 16 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   id                      29224 non-null  int64
 1   bhch04                  29224 non-null  int64
 2   quintil_uc              29224 non-null  int64
 3   promedio_fv_diario      28471 non-null  float64
 4   consumo_fv              29224 non-null  int64
 5   barreras_fyv            29224 non-null  int64
 6   bial01                  29224 non-null  int64
 7   bial02                  29224 non-null  int64
 8   bial08                  29224 non-null  int64
 9   nivel_actividad_fisica  28970 non-null  float64
 10  bima07                  16491 non-null  float64
 11  bima10                  16425 non-null  float64
 12  imc_bima                16410 non-null  float64
 13  bima13                  16312 non-null  float64
 14  promedio_sistolica      16227 non-null  float64
 15  bimq05                  5188 non-null   float64
dtypes: float64(8), int64(8)
memory usage: 3.6 MB
```

Fig. 1: Resumen estructural de la base con las 16 variables seleccionadas (29.224 registros): tipo de dato y cantidad de valores no nulos por variable. Las mediciones físicas tienen entre 16.227 y 16.491 valores y la glucemia (bimq05) solo 5.188, por el diseño de la encuesta en pasos.

En la Fig. 2 se observa la cantidad de valores faltantes por variable, según se calcula en la Sección 2.0 del código fuente. Los faltantes se concentran en las mediciones de los pasos 2 y 3 de la encuesta (peso, talla, IMC, cintura, presión y glucemia), mientras que las variables de autorreporte están casi completas. Los códigos 99 (Ns/Nc) de consumo_fv, bial01 y bial08 no aparecen aquí porque todavía no estaban recodificados como NaN; se tratan en la Sección 2.1.

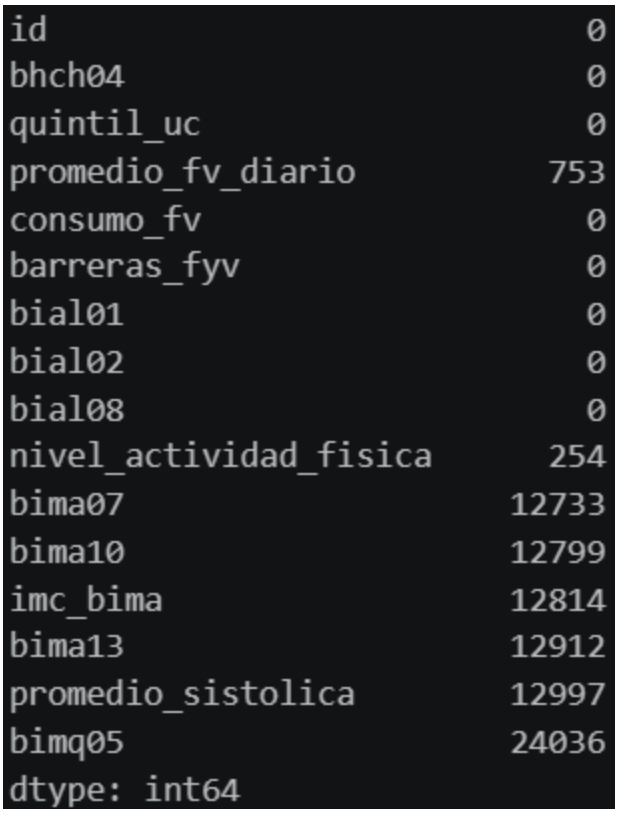


Fig. 2: Cantidad de valores faltantes (NaN) originales por variable, antes de recodificar el código 99 (Ns/Nc). Las mediciones físicas faltan en 12.733 a 12.997 registros (cerca del 44%) y la glucemia (bimq05) en 24.036 (82%); las variables de autorreporte casi no tienen faltantes.

En la Fig. 3 se observa la búsqueda del código 99 (No sabe / No contesta), según se calcula en la Sección 2.1 del código fuente. Aparece en consumo_fv (753 registros, 2,58%), bial01 (98, 0,34%) y bial08 (79, 0,27%), y se recodificó como NaN para que todos los nulos tengan el mismo formato. nivel_actividad_fisica no usa ese código: sus 254 faltantes (0,87%) ya eran NaN.

```
consumo_fv
2     26699
1      1772
99      753
Name: count, dtype: int64
---
bial01
1     20780
2      8346
99       98
Name: count, dtype: int64
---
bial08
2     16622
3      7248
1      4824
4       451
99       79
Name: count, dtype: int64
---
nivel_actividad_fisica
3.0    13764
2.0    10347
1.0     4859
Name: count, dtype: int64
```

Fig. 3: Frecuencia de cada categoría de consumo_fv, bial01, bial08 y nivel_actividad_fisica. El código 99 (Ns/Nc) aparece en 753, 98 y 79 registros de las tres primeras; nivel_actividad_fisica no lo tiene.

En la Fig. 4 se observa el resultado de recodificar el código 99 como NaN, según se calcula en la Sección 2.2 del código fuente. La base del INDEC usa los códigos 99, 999 y 9999 para identificar nulos, pero en las variables seleccionadas solo aparece el 99, por lo que no se consideraron los otros dos. A partir de este paso todos los nulos tienen el mismo formato.

```
id                          0
bhch04                      0
quintil_uc                  0
promedio_fv_diario        753
consumo_fv                753
barreras_fyv                0
bial01                     98
bial02                      0
bial08                     79
nivel_actividad_fisica    254
bima07                  12733
bima10                  12799
imc_bima                12814
bima13                  12912
promedio_sistolica      12997
bimq05                  24036
dtype: int64
```

Fig. 4: Cantidad de valores nulos por variable después de recodificar el código 99 (Ns/Nc) como valor faltante. consumo_fv, bial01 y bial08 pasan a tener 753, 98 y 79 nulos; el resto de las variables mantiene los faltantes originales.

En la Tabla 1 se observa la cantidad y el porcentaje de nulos de cada variable seleccionada, según se calcula en la Sección 2.3 del código fuente. Los mayores porcentajes corresponden a la glucemia (82,25%) y a las mediciones físicas del paso 2 (entre 43,57% y 44,47%), por el diseño de la encuesta. Las variables restantes tienen menos de 3% de nulos. Estos porcentajes se usaron para elegir la técnica de tratamiento de nulos.

	nulos	porcentaje
bimq05	24036	82.25
promedio_sistolica	12997	44.47
bima13	12912	44.18
imc_bima	12814	43.85
bima10	12799	43.80
bima07	12733	43.57
promedio_fv_diario	753	2.58
consumo_fv	753	2.58
nivel_actividad_fisica	254	0.87
bial01	98	0.34
bial08	79	0.27
bial02	0	0.00
barreras_fyv	0	0.00
bhch04	0	0.00
quintil_uc	0	0.00

Tabla 1: Cantidad y porcentaje de valores nulos por variable seleccionada, ordenadas de mayor a menor, sobre 29.224 registros. La glucemia (bimq05) tiene 82,25% de nulos, las mediciones físicas entre 43,57% y 44,47%, y el resto de las variables menos de 3%.

Conclusión de limpieza de nulos

Los nulos de la ENFR 2018 se resolvieron eliminando filas por hipótesis, sin imputar, y esa decisión es sólida para la mayoría de los casos y tiene un costo declarado en 4c.

Un solo tipo de nulo. El código 99 (Ns/Nc) se recodificó a NaN, por lo que todos los nulos de la base se cuentan con el mismo criterio. De las variables de interés, cinco no tienen nulos, las de alimentación y actividad física tienen menos de 3%, las mediciones físicas cerca de 44% y la glucemia 82%.

Mecanismo. Los nulos Ns/Nc, los de actividad física y los de la submuestra 0 son MCAR en la práctica (efectos con V de Cramér menor a 0,10). Los que quedan dentro de la submuestra 1 en mediciones físicas y glucemia son MAR, porque dependen de la región.

Tratamiento: Cada hipótesis elimina, con dropna(subset=...), solo las filas con NaN en las variables que usa. Dejan 29.224 casos la univariada, 28.471 la bivariada y 4a, 16.282 la 4b y 5.039 la 4c. Eliminar filas es seguro bajo MCAR, y aquí la pérdida es mínima (por ejemplo, 753 de 29.224 en frutas y verduras deja el 97,4% de la base), así que no hay motivo para imputar.

Alcance: Los resultados de 4b y 4c valen para la población efectivamente medida. En 4c el n es el 17% de la base y los nulos MAR por región pueden sesgar la composición de la muestra; el uso de los ponderadores queda como decisión pendiente del grupo.

En la Tabla 2 se observan los estadísticos descriptivos de las variables, según se calcula en la Sección 2.4 del código fuente. La edad va de 18 a 104 años, con media de 46,5 y mediana de 44. La talla es simétrica (media 164,2 cm y mediana 164 cm), mientras que el consumo de frutas y verduras (media 2,07 y mediana 1,64 porciones), el IMC (28,2 contra 27,4) y el peso (76,1 kg de media, con máximo de 200 kg) presentan media mayor que la mediana y valores máximos muy alejados del tercer cuartil, lo que confirma la asimetría a la derecha y la presencia de valores atípicos.

	id	bhch04	quintil_uc	promedio_fv_diario	barreras_fyv	bial02	nivel_actividad_fisica	bima07
count	2.922400e+04	29224.000000	29224.000000	28471.000000	29224.000000	29224.000000	28970.000000	16491.000000
mean	1.075470e+09	46.489084	3.006878	2.071157	2.782610	2.505304	2.307387	164.182221
std	6.223720e+08	18.052815	1.413652	1.708309	1.332819	0.714944	0.740520	9.705348
min	1.171400e+04	18.000000	1.000000	0.000000	1.000000	1.000000	1.000000	114.000000
25%	5.358276e+08	32.000000	2.000000	1.000000	1.000000	2.000000	2.000000	157.000000
50%	1.079500e+09	44.000000	3.000000	1.640000	3.000000	3.000000	2.000000	164.000000
75%	1.622154e+09	61.000000	4.000000	2.710000	4.000000	3.000000	3.000000	171.000000
max	2.147433e+09	104.000000	5.000000	18.000000	5.000000	3.000000	3.000000	201.000000

bima10	imc_bima	bima13	promedio_sistolica	bimq05
16425.000000	16410.000000	16312.000000	16227.000000	5188.000000
76.143805	28.221648	91.938389	130.650490	80.867965
17.421392	5.919656	15.948493	20.888462	30.903372
33.000000	14.150000	40.000000	67.000000	20.000000
64.000000	24.010000	81.000000	116.000000	65.000000
74.000000	27.410000	92.000000	127.500000	79.000000
86.000000	31.550000	102.000000	141.500000	92.000000
200.000000	86.570000	230.000000	249.000000	382.000000

Tabla 2: Estadísticos descriptivos (cantidad, media, desvío, mínimo, cuartiles y máximo) de las variables numéricas luego de corregir los nulos. En frutas y verduras, IMC y cintura la media supera a la mediana, lo que indica asimetría a la derecha.

En la Tabla 3 se observa la cantidad de valores atípicos de cada variable cuantitativa, según se calcula en la Sección 3.0 del código fuente con el criterio del rango intercuartílico. Todas las variables medidas presentan outliers, que representan entre 0,25% y 4,84% de los valores disponibles. No se eliminaron, porque corresponden a mediciones plausibles y son pocos respecto del total.

	Cantidad de Outliers	Porcentaje (%)	Presencia de Outliers
bhch04	0	0.00	False
promedio_fv_diario	1206	4.13	True
bima07	41	0.14	True
bima10	301	1.03	True
imc_bima	343	1.17	True
bima13	170	0.58	True
promedio_sistolica	456	1.56	True
bimq05	251	0.86	True

Tabla 3: Cantidad y porcentaje de valores atípicos por variable cuantitativa, según el criterio del rango intercuartílico (fuera de Q1 − 1,5·IQR y Q3 + 1,5·IQR). Todas presentan outliers salvo la edad; los mayores porcentajes son glucemia (4,84%) y frutas y verduras (4,24%).

En la Fig. 5 se observa la matriz de correlaciones de Pearson, según se calcula en la Sección 4.0 del código fuente. Las mediciones antropométricas están fuertemente correlacionadas entre sí (peso–IMC 0,85, IMC–cintura 0,80, peso–cintura 0,79), como es esperable porque el IMC se calcula a partir del peso. La presión sistólica se asocia positivamente con la edad (0,42), la cintura (0,36), el IMC (0,31) y el peso (0,29), lo que motivó las hipótesis 3.5 y 3.6. El consumo de frutas y verduras muestra correlaciones débiles con el resto (por ejemplo, 0,15 con el quintil de ingreso), coherente con la hipótesis 3.3.

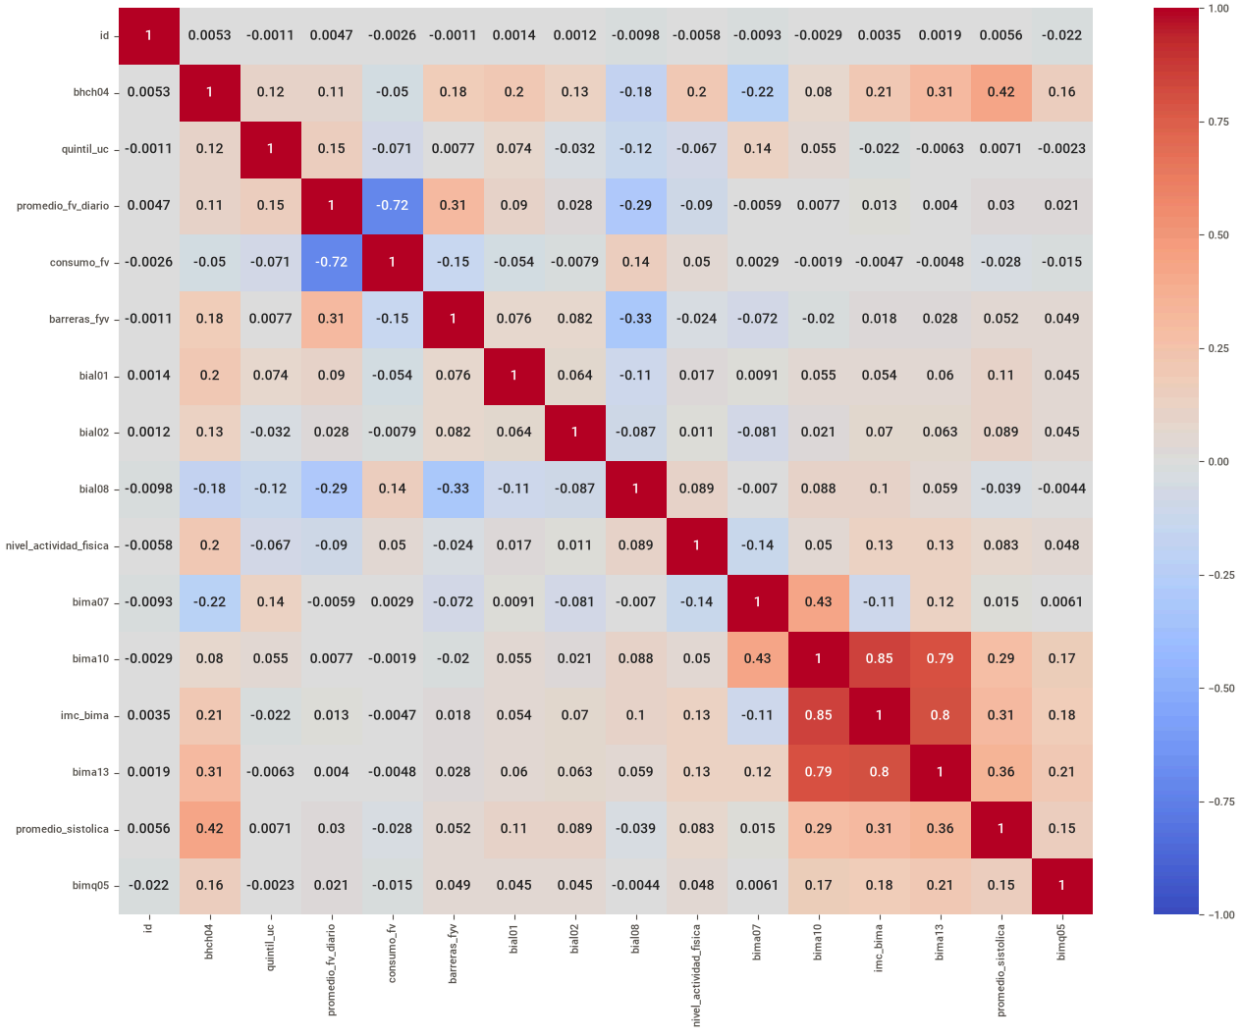


Fig. 5: Mapa de calor de las correlaciones de Pearson entre las variables seleccionadas (rojo: positiva, azul: negativa). Las más fuertes son peso–IMC (0,85), IMC–cintura (0,80) y peso–cintura (0,79); la edad es la que más se asocia con la presión sistólica (0,42).

3. Hipótesis y resolución

3.1. Hipótesis Univariada 1:

3.1.1. Definición de la hipótesis

A partir del análisis exploratorio de la variable cualitativa ordinal bial02 (“Habitualmente, ¿le agrega sal a los alimentos una vez que está cocidos o al sentarse a la mesa… ”, codificada como 1: Siempre o casi siempre, 2: Raras veces, 3: Nunca), Se plantea la como hipótesis que más del 50% de la población adulta Argentina nunca agrega sal a las comidas en la mesa.

Formalmente, definiendo un indicador donde el valor 1 representa a las personas que “Nunca” agregan sal y 0 a quienes sí lo hacen (“Siempre/casi siempre” o “Raras veces”), se contrastan las siguientes hipótesis estadísticas con un nivel de significancia α=0,05:

$$H_0: \ La\ proporción\ de\ personas\ que\ "Nunca"\ agregan\ sal\ en\ la\ mesa\ es \leq 50\%\ (p \leq 0,50)$$

$$H_1: \ La\ proporción\ de\ personas\ que\ "Nunca"\ agregan\ sal\ en\ la\ mesa\ es\ > 50\%\ (p > 0,50)$$

3.1.2. Estrategia de abordaje

Para abordar y validar esta hipótesis se siguió una metodología en tres etapas:

1. Resumen estadístico descriptivo: En primer lugar, se construyó una tabla de distribución de frecuencias absolutas, porcentajes relativos y porcentajes acumulados sobre el total de encuestados válidos para cuantificar el peso de cada categoría de la variable bial02.
2. Exploración visual: Se realizó un gráfico de barras con los porcentajes de cada categoría incorporando una línea horizontal de referencia en el 50% establecido en la hipótesis nula.
3. Contraste de hipótesis:: Siguiendo el flujo de decisión visto en la cátedra para una muestra contra un valor de referencia (μ0=0,50):
    - Primero se evaluó el supuesto de normalidad mediante el test de Kolmogorov Smirnov previa estandarización de la muestra.
    - Dado que la variable indicadora no sigue una distribución normal (p<0,05), se descartó el test paramétrico (test t de 1 muestra) y se aplicó su

alternativa no paramétrica: la Prueba de los rangos con signo de Wilcoxon para 1 muestra.

3.1.3. Resultados obtenidos y discusión

Al calcular la tabla de frecuencias sobre los 29.224 registros de la muestra, se obtuvieron los siguiente valores descriptivos**:**

	Hábito de agregar sal en la mesa (bial02)	N	Porcentaje (%)	% Acumulado
0	Siempre o casi siempre	3816	13.06	13.06
1	Raras veces	6825	23.35	36.41
2	Nunca	18583	63.59	100.00

Tabla 1: Distribución de frecuencias de la variable bial02 (hábito de agregar sal en la mesa) sobre 29.224 encuestados. El 63,59% (18.583 personas) nunca agrega sal, el 23,35% (6.825) lo hace raras veces y el 13,06% (3.816) siempre o casi siempre.

Como se observa en el cuadro, el 63,59% de los encuestados declaró que nunca agrega sal en la mesa, frente a un 23,35% que lo hace raras veces y un 13,06% que lo hace siempre o casi siempre.

Esta tendencia se visualiza claramente en el gráfico de barras, donde la categoría 3, nunca supera con amplio margen la línea punteada del umbral del 50%:

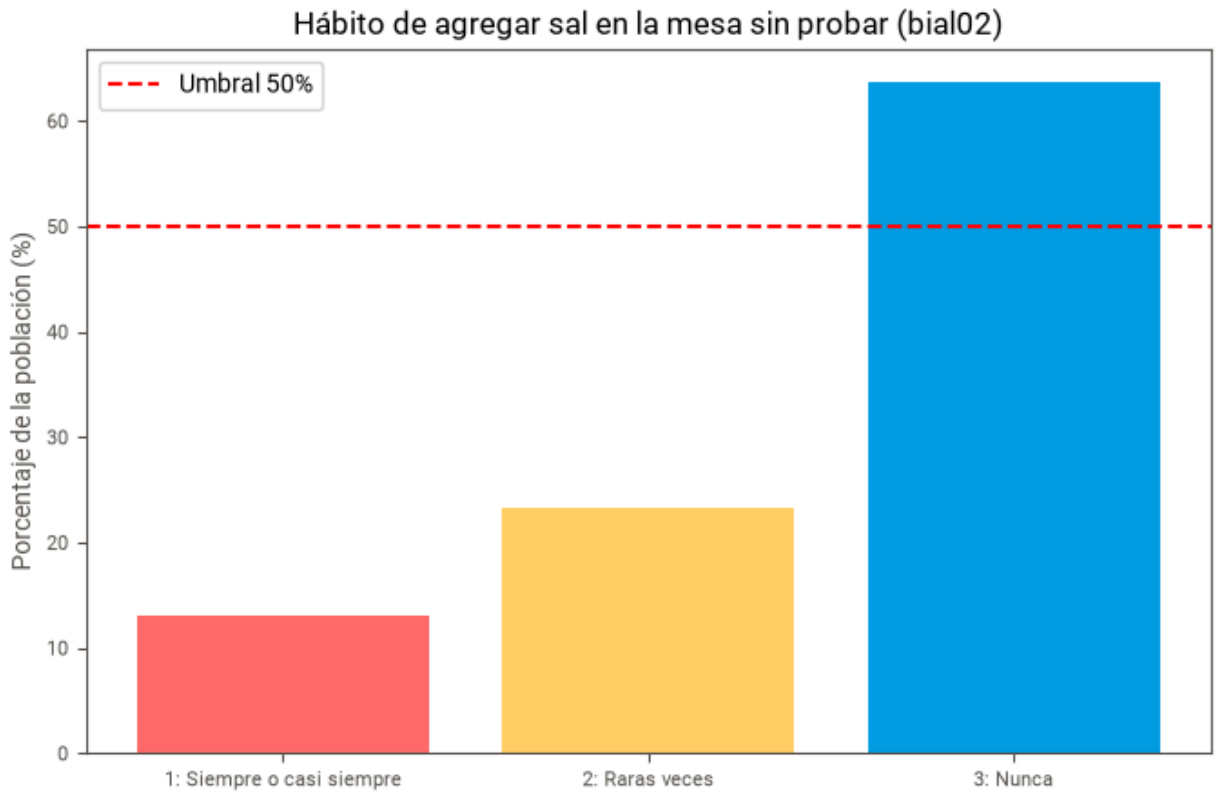


Fig. 1: Porcentaje de la población según el hábito de agregar sal en la mesa sin probar la comida (bial02). La categoría "Nunca" alcanza el 63,59% y supera el umbral del 50% planteado en la hipótesis nula, mientras que "Raras veces" y "Siempre o casi siempre" quedan en 23,35% y 13,06%.

Finalmente, al ejecutar la validación estadística formal se obtuvieron los siguientes resultados:

- Proporción muestral observada (Nunca agrega sal): 63,59%
- Test de Normalidad de Kolmogorov Smirnov: Estadístico D=0,500, p-valor=0,0000<0,05, entonces, se rechaza la hipótesis de normalidad.
- Prueba de Wilcoxon para 1 muestra: Estadístico W = 271.544.087,5, p-valor=0,0000<0,05.

Conclusión:

Dado que el p-valor obtenido (0) es menor al nivel de significancia α=0,05, se rechaza la hipótesis nula (H0) en favor de la hipótesis alternativa (H1). Existe evidencia estadística significativa para concluir que más del 50% de la población adulta argentina nunca agrega sal a los alimentos al sentarse a la mesa.

3.2. Hipótesis Univariada(Catedra) 2:

3.2.1. Definición de la hipótesis

Se analiza la variable cuantitativa promedio_fv_diario("Promedio de consumo diario de frutas o verduras [Cantidad en porciones]"). La hipótesis es que el consumo diario de frutas y verduras de la población adulta argentina es inferior a las 5 porciones diarias que recomienda la OMS.

Con un nivel de significancia α=0,05, las hipótesis estadísticas son:

$$H_0: \textit{El consumo medio diario es de } 5 \textit{ porciones o más } (\mu \geq 5)$$

$$H_1: \textit{El consumo medio diario es menor a } 5 \textit{ porciones } (\mu < 5).$$

3.2.2. Estrategia de abordaje

Para abordar y validar esta hipótesis se siguió una metodología en tres etapas:

1. Exploración visual: Se realizó un histograma de la variable promedio_fv_diario sobre los encuestados con datos válidos, incorporando una línea vertical de referencia en las 5 porciones recomendadas por la OMS y marcas con la media y la mediana de la distribución.
2. Evaluación de normalidad: Se evaluó el supuesto de normalidad mediante el test de Kolmogorov Smirnov, previa estandarización de la muestra.
3. Contraste de hipótesis: Siguiendo el flujo de decisión visto en la cátedra para una muestra contra un valor de referencia (μ0=5):
    - Dado que la variable no sigue una distribución normal (p < 0,05), se descartó el test paramétrico (test t de 1 muestra) y se aplicó su alternativa no paramétrica: la Prueba de los rangos con signo de Wilcoxon para 1 muestra.

3.2.3. Resultados obtenidos y discusión

El histograma muestra que la gran mayoría de las personas consume muy por debajo de las 5 porciones recomendadas:

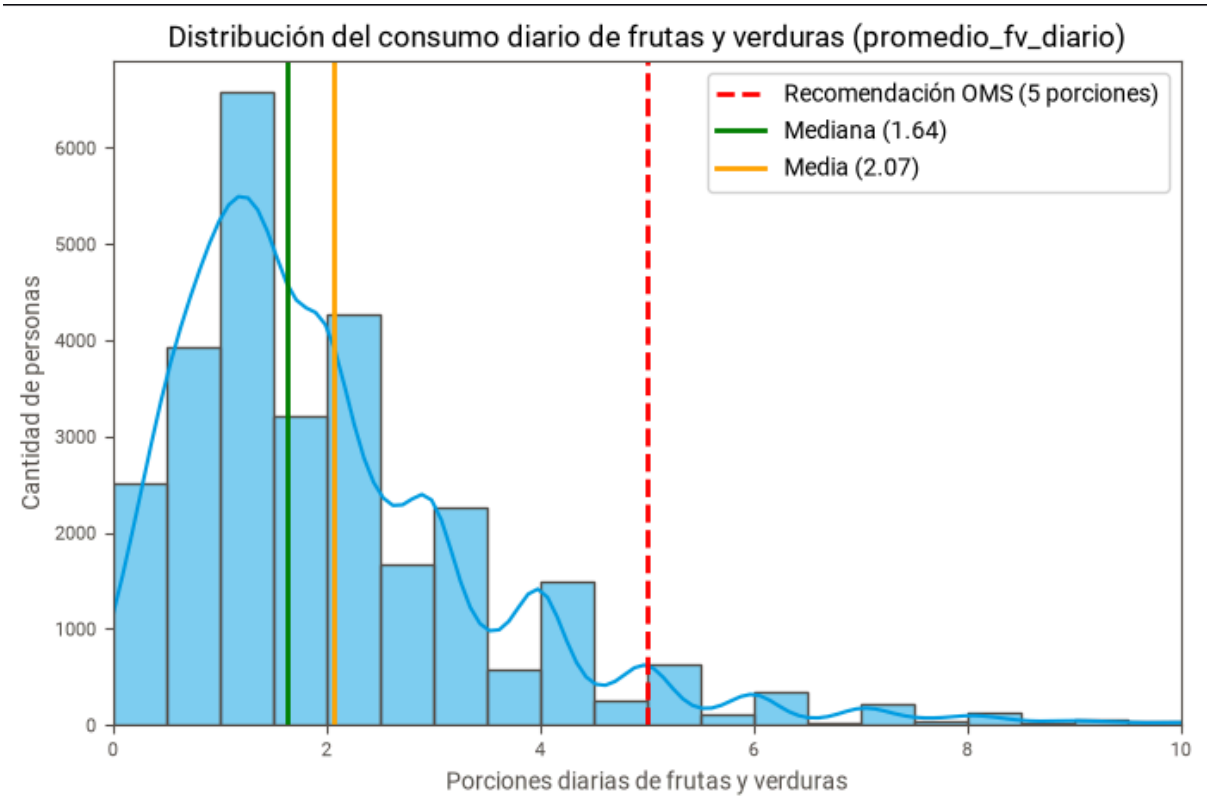


Fig. 2: Distribución del consumo diario de frutas y verduras (promedio_fv_diario) en la población adulta encuestada. La mediana es de 1,64 y la media de 2,07 porciones por día, ambas muy por debajo de las 5 porciones recomendadas por la OMS. La distribución está sesgada a la derecha y muy pocas personas superan ese umbral.

La mediana es de 1,64 porciones y la media de 2,07. Ambas están muy lejos de la línea roja de las 5 porciones.

La distribución está sesgada a la derecha: la mayor parte de las personas consume entre 1 y 2 porciones por día, y muy pocas superan el umbral de la OMS.

Resultados de las pruebas estadísticas:

- Test de Kolmogorov Smirnov: D=0,628, p-valor = 0,0000 < 0,05, entonces, se rechaza la normalidad.
- Prueba de Wilcoxon para 1 muestra: W = 11.004.585,0, p-valor=0,0000 < 0,05.

Conclusión:

Como el p-valor es menor a 0,05, se rechaza la hipótesis nula. Hay evidencia estadística de que el consumo diario de frutas y verduras de la población adulta argentina es significativamente menor a las 5 porciones recomendadas por la OMS.

3.3. Hipótesis Bivariada 1:

3.3.1. Definición de la hipótesis

A partir del cruce entre la variable cualitativa ordinal quintil_uc ("Quintil de hogares según ingreso por unidad consumidora ", donde 1 corresponde al 20% de hogares de menores ingresos y 5 al 20% de mayores ingresos) y la variable cuantitativa continua promedio_fv_diario ("Promedio de consumo diario de frutas o verduras [Cantidad en porciones]"), se plantea como hipótesis que el consumo diario de frutas y verduras varía según el nivel socioeconómico del hogar, asociándose positivamente con el quintil de ingresos .

Formalmente, para contrastar si existen diferencias estadísticamente significativas entre los 5 grupos independientes con un nivel de significancia α=0,05, se plantean las siguientes hipótesis estadísticas:

$$H_0: \ la\ distribución\ de\ promedio_fv_diario\ es\ igual\ en\ los\ 5\ quintiles$$

$$H_1: \ al\ menos\ un\ quintil\ presenta\ una\ distribución\ distinta$$

3.3.2. Estrategia de abordaje

Para analizar y validar esta hipótesis bivariada se aplicó el siguiente procedimiento en tres etapas:

1. Resumen estadístico por grupos: Se filtraron los registros con datos válidos en ambas variables (N=28.471) y se agruparon según quintil_uc (1 a 5), calculando para cada grupo el tamaño muestral , la media, la mediana, el desvío estándar, los valores mínimo y máximo, y el porcentaje de personas que alcanza la recomendación de la OMS (≥5 porciones diarias).
2. Exploración visual comparativa: Se generó un gráfico de cajas (boxplot) comparando la distribución de promedio_fv_diario en los 5 quintiles de ingreso (ocultando los outliers para visualizar con claridad la mediana y el rango

intercuartílico de cada grupo), junto con una línea horizontal punteada indicando la meta de 5 porciones diarias de la OMS.

3. Contraste de hipótesis para k>2 muestras independientes: Siguiendo el árbol de decisión de la cátedra para comparar múltiples grupos independientes:
    - Primero se verificó el supuesto de normalidad dentro de cada uno de los 5 quintiles mediante el Test de Kolmogorov Smirnov previa estandarización de cada submuestra. En segundo lugar, se evaluó el supuesto de homocedasticidad (igualdad de varianzas entre los 5 quintiles) mediante el Test de Levene.
    - Dado que no se cumplieron los supuestos paramétricos ($p<0,05$ tanto en normalidad como en homocedasticidad), se descartó el test ANOVA y se aplicó su alternativa no paramétrica: El test de Kruskal Wallis.

3.3.3. Resultados obtenidos y discusión

En la siguiente tabla se presentan las métricas descriptivas del consumo diario de frutas y verduras desagregadas por quintil de ingreso:

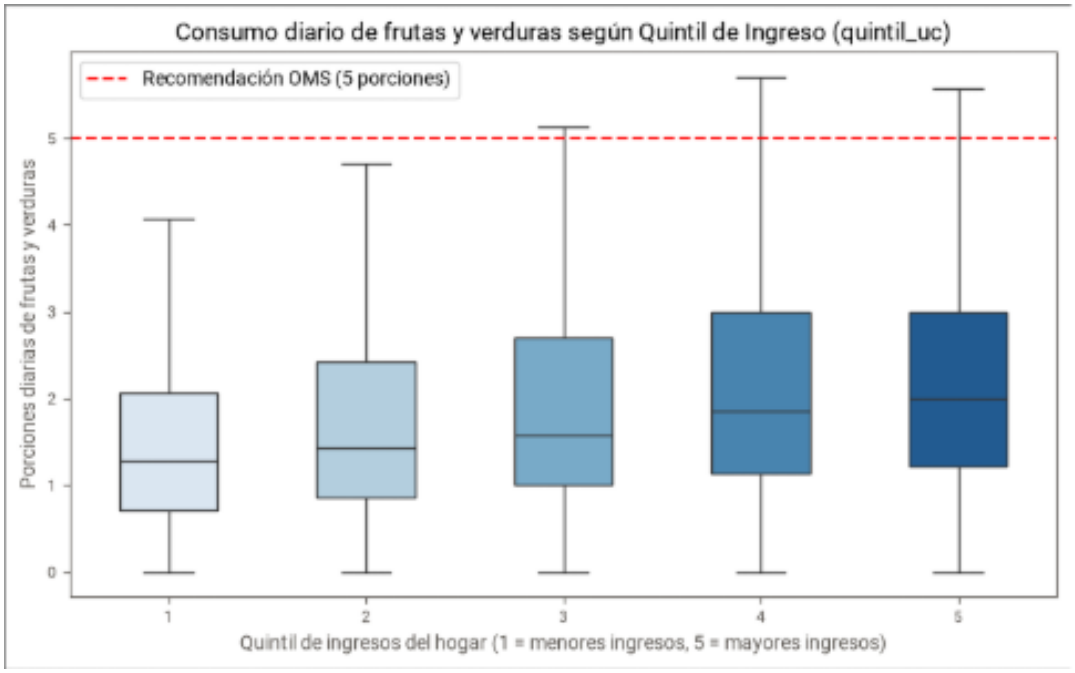


Fig. 3: Consumo diario de frutas y verduras según el quintil de ingreso del hogar (quintil_uc), sin mostrar valores atípicos. La mediana y el tercer cuartil aumentan del quintil 1 (menores ingresos) al quintil 5 (mayores ingresos), y en ningún quintil la mediana se acerca a las 5 porciones de la OMS.

Los datos muestran claramente cómo el consumo de frutas y verduras va subiendo a medida que aumenta el nivel de ingresos del hogar:

- El Quintil 1 tiene un promedio de apenas 1,71 porciones diarias (mediana de 1,29) y solo el 3,86% de las personas llega al mínimo recomendado de 5 porciones.
- Este promedio sube escalón por escalón en los quintiles siguientes (1,91 en el Q2, 2,05 en el Q3 y 2,24 en el Q4) hasta llegar al Quintil 5, que alcanza un promedio de 2,43 porciones diarias (mediana de 2,00) y más del doble de personas que cumplen con la recomendación de la OMS (8,75%).

Esta suba en la mediana y en el tamaño de las cajas a medida que aumenta el quintil de ingreso se ve claramente en el siguiente gráfico de cajas:

	Quintil de Ingreso	N	Media (porciones/dia)	Mediana	Desvío Estándar	Mínimo	Máximo	% Cumple OMS (>=5)
0	1	5513	1.71	1.29	1.54	0.0	14.0	3.86
1	2	5778	1.91	1.43	1.61	0.0	17.0	5.07
2	3	5555	2.05	1.57	1.67	0.0	18.0	5.78
3	4	5867	2.24	1.86	1.80	0.0	17.0	7.52
4	5	5758	2.43	2.00	1.81	0.0	18.0	8.75

Tabla 2: Estadísticos descriptivos del consumo diario de frutas y verduras por quintil de ingreso. La media sube de 1,71 porciones en el quintil 1 a 2,43 en el quintil 5, y el porcentaje de personas que cumple la recomendación de la OMS (≥ 5 porciones) pasa de 3,86% a 8,75%.

Por último, al ejecutar las pruebas de validación estadística se obtuvieron los siguientes resultados:

- Test de Normalidad de Kolmogorov Smirnov por quintil: p-valores: Q1=0,0000; Q2=0,0000; Q3=0,0000; Q4=0,0000; Q5=0,0000, Entonces, Se rechaza la normalidad en todos los grupos ($p<0,05$).
- Test de Homocedasticidad de Levene: Estadístico F=37,35, p-valor= $3,32\times 10^{-31}$ < 0,05, entonces, se rechaza la igualdad de varianzas entre los quintiles.
- Prueba de Kruskal Wallis (No paramétrico): Estadístico H=940,75, p-valor = $2,47\times 10^{-202}$<0,05.

Conclusión:

Como el p-valor de la prueba de Kruskal Wallis es mucho menor a 0,05, se rechaza la hipótesis nula. Con esto se confirma que al menos un quintil tiene una distribución distinta y que el consumo diario de frutas y verduras cambia según el nivel de ingresos del hogar: a menor ingreso, menor es el consumo de estos alimentos.

3.4. Hipótesis Bivariada(Catedra) 2:

3.4.1. Definición de la hipótesis

Se cruzan la variable cuantitativa imc_bima ("Índice de masa corporal según mediciones antropométricas ") con la variable cualitativa ordinal nivel_actividad_fisica (1: Alto, 2: Medio, 3: Bajo). La hipótesis es que el IMC cambia según el nivel de actividad física de las personas.

Con un nivel de significancia α=0,05:

$$H_0: \textit{La distribución del IMC es la misma en los tres niveles de actividad física}$$

$$H_1: \textit{Al menos un nivel de actividad física presenta una distribución de IMC distinta}$$

3.4.2. Estrategia de abordaje

Para abordar y validar esta hipótesis se siguió una metodología en tres etapas:

1. Exploración visual: Se realizó un gráfico de cajas (boxplot) del IMC para cada nivel de actividad física, ocultando outliers e incorporando líneas horizontales de referencia en los umbrales de sobrepeso (IMC = 25) y obesidad (IMC = 30).
2. Evaluación de supuestos: Se evaluó la normalidad del IMC dentro de cada grupo mediante el test de Kolmogorov Smirnov, previa estandarización, y la homocedasticidad mediante el test de Levene.
3. Contraste de hipótesis: Siguiendo el flujo de decisión visto en la cátedra para comparar más de dos grupos independientes, como no se cumplieron los supuestos ($p<0,05$), se descartó el test ANOVA y se aplicó su alternativa no paramétrica: la Prueba de Kruskal Wallis.

3.4.3. Resultados obtenidos y discusión

El gráfico de cajas muestra que el IMC aumenta a medida que baja el nivel de actividad física:

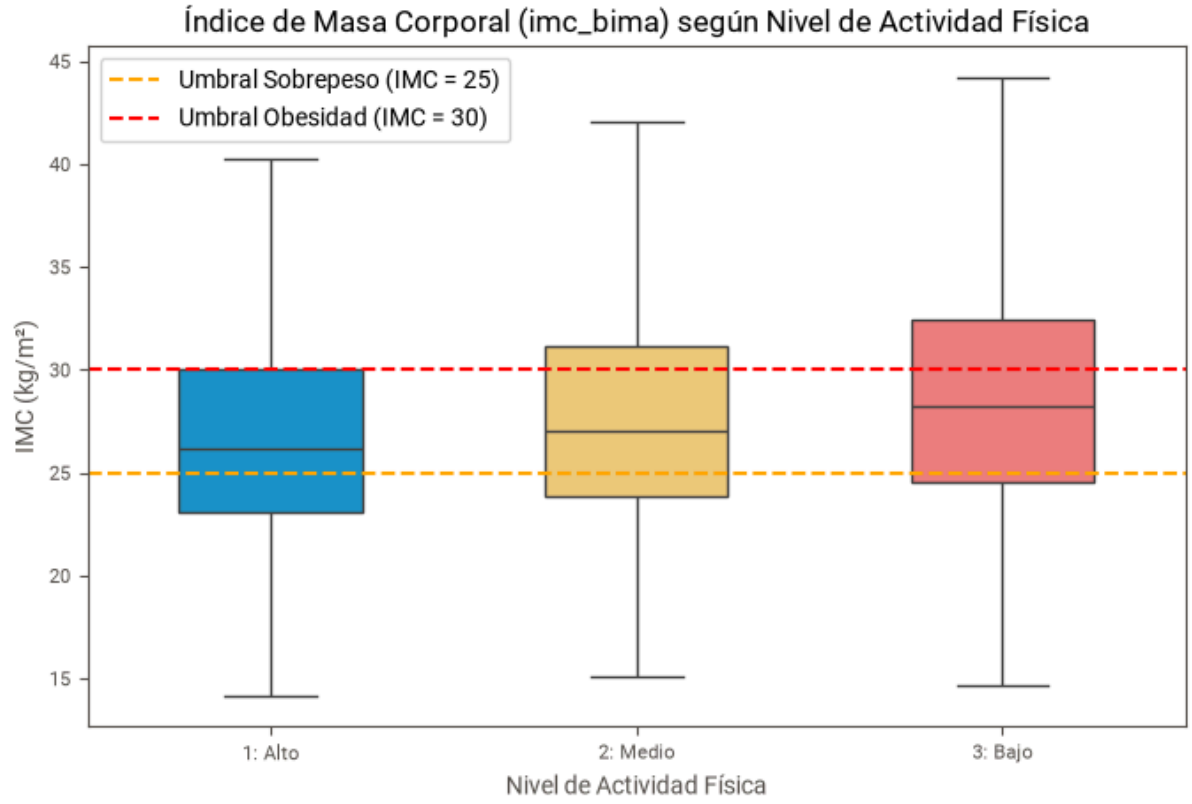


Fig. 4: índice de masa corporal (imc_bima) según nivel de actividad física, sin mostrar outliers. La mediana aumenta de actividad alta (cerca de 26) a media (cerca de 27) y baja (cerca de 28). Solo en el grupo de actividad baja el tercer cuartil supera el umbral de obesidad (IMC = 30).

En el grupo de actividad física alta, la mediana del IMC ronda los 26, apenas por encima del umbral de sobrepeso.

- En el grupo medio, la mediana sube a cerca de 27
- En el grupo de actividad física baja, la mediana es de aproximadamente 28 y la caja se acerca más al umbral de obesidad (30). Además, el tercer cuartil supera ese umbral.

Resultados de las pruebas estadísticas:

- Test de Kolmogorov Smirnov por nivel:p-valores: Alto =0,0000; Medio =0,0000; Bajo = 0,0000, entonces, se rechaza la normalidad en los tres grupos.
- Supuestos: como no se cumplen normalidad ni homocedasticidad, se aplica una prueba no paramétrica.
- Prueba de Kruskal Wallis: H=271,83, p-valor= $9{,}38\times 10^{-60} < 0{,}05$.

Conclusión:

Como el p-valor es mucho menor a 0,05, se rechaza la hipótesis nula. El IMC cambia significativamente según el nivel de actividad física: a menor actividad física, mayor IMC.

3.5. Hipótesis Multivariada 1:

3.5.1. Definición de la hipótesis

Se plantea explicar la presión arterial sistólica (promedio_sistolica) a partir de la edad (bhch04), el peso (bima10), la altura (bima07) y el consumo diario de frutas y verduras (promedio_fv_diario). La hipótesis es que existe una relación lineal entre la presión sistólica y estas cuatro variables.

- Modelo

$$PAS_i = \beta_0 + \beta_1 edad_i + \beta_2 Peso_i + \beta_3 Altura_i + \beta_4 Consumo_i + \varepsilon_i$$

- Hipótesis estadísticas

$$H_0: \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0 \quad H_1: \text{al menos un } \beta_j \neq 0$$

	Grupo de Edad	Rango de Peso	N	Edad Media (años)	Peso Medio (kg)	Talla Media (cm)	Media F&V (porc/día)	Media Sistólica (mmHg)	Mediana Sistólica	Desvío Estándar	% Presión >=140 mmHg
0	18 a 44 años	Menor a 70 kg	3487	29.6	59.4	161.8	1.93	116.69	115.0	13.40	5.51
1	18 a 44 años	70 a 84.9 kg	2462	31.8	76.4	167.8	1.83	124.37	123.0	14.54	13.36
2	18 a 44 años	85 kg o más	2009	33.5	98.3	170.8	1.82	130.57	128.5	15.72	24.89
3	45 o más años	Menor a 70 kg	2562	63.2	60.7	157.1	2.16	134.32	131.0	22.97	35.25
4	45 o más años	70 a 84.9 kg	2732	61.8	76.8	162.5	2.21	139.16	136.0	21.96	43.63
5	45 o más años	85 kg o más	2379	59.5	97.5	167.9	2.21	143.37	140.5	21.36	52.04

Tabla 3: Estadísticos descriptivos por grupo de edad (18 a 44 y 45 o más años) y rango de peso (menor a 70 kg, 70 a 84,9 kg y 85 kg o más). La presión sistólica media crece con la edad y el peso: va de 116,69 mmHg (18 a 44 años, menos de 70 kg) a 143,37 mmHg (45 o más años, 85 kg o más). En ese último grupo el 52,04% tiene presión ≥ 140 mmHg, frente al 5,51% en el primero.

3.5.2. Estrategia de abordaje

Para validar esta hipótesis se siguió una metodología en cuatro etapas:

1. Preparación de los datos: Se seleccionaron los encuestados con datos válidos en las cinco variables (N=15.631). Se separó la variable objetivo de las predictoras y se estandarizaron estas últimas.
2. Ajuste del modelo: Se ajustó una regresión lineal múltiple por mínimos cuadrados y se analizó el summary(): R^2, estadístico F y coeficientes.
3. Verificación de supuestos: Se evaluó la normalidad de los residuos con un QQ-Plot y los tests de Omnibus y Jarque-Bera. Se evaluó la homocedasticidad con el gráfico de valores ajustados vs. residuos, y la independencia de los errores con el estadístico de Durbin Watson.
4. Conclusión: Se interpretaron los resultados teniendo en cuenta si los supuestos se cumplen.

3.5.3. Resultados obtenidos y discusión

```
                            OLS Regression Results
==============================================================================
Dep. Variable:     promedio_sistolica   R-squared:                       0.245
Model:                            OLS   Adj. R-squared:                  0.245
Method:                 Least Squares   F-statistic:                     1270.
Date:                Sun, 08 Nov 2026   Prob (F-statistic):               0.00
Time:                        19:42:59   Log-Likelihood:                -67450.
No. Observations:               15631   AIC:                         1.349e+05
Df Residuals:                   15626   BIC:                         1.349e+05
Df Model:                           4
Covariance Type:            nonrobust
==========================================================================================
                             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------------------
const                    130.5595      0.145    901.417      0.000     130.276     130.843
bhch04                     8.4166      0.153     55.185      0.000       8.118       8.716
bima10                     5.3956      0.164     32.980      0.000       5.075       5.716
bima07                    -0.1440      0.167     -0.861      0.389      -0.472       0.184
promedio_fv_diario        -0.2945      0.146     -2.021      0.043      -0.580      -0.009
==============================================================================
Omnibus:                     2539.454   Durbin-Watson:                   1.976
Prob(Omnibus):                  0.000   Jarque-Bera (JB):             5879.980
Skew:                           0.936   Prob(JB):                         0.00
Kurtosis:                       5.350   Cond. No.                         1.74
==============================================================================
```

Fig. 5: Resumen (summary) del modelo de regresión lineal múltiple de la presión sistólica (promedio_sistolica) según edad, peso, altura y consumo de frutas y verduras, con N=15.631. El R^2 es 0,245 y el modelo es significativo en conjunto (F=1270, p<0,001). La edad (8,42) y el peso (5,40) son los coeficientes más influyentes. La altura no es significativa (p=0,389).

Explicación del summary:

R2:

El coeficiente de determinación R2 es una medida estadística que indica qué proporción de la varianza en la variable dependiente (o respuesta) es explicada por el modelo de regresión lineal. De alguna forma, R2 nos ayuda a entender entonces qué tan bien el modelo ajusta los datos. El valor de R2 debería variar entre 0 y 1.

En nuestro caso, vemos que obtuvimos un R2 de 0.245. Esto indica que el modelo explica aproximadamente el 24.5% de la varianza de promedio_sistolica a partir de bhch04, bima10, bima07 y promedio_fv_diario. Esto sugiere que estos predictores no

funcionan del todo bien, ya que aún falta muchísima varianza sin explicar, posiblemente debido a otros factores o variables no incluidas en el modelo, presencia de outliers o a ruido que no hemos podido capturar. Hay que tener en cuenta que la presión arterial no tiene un factor único de dependencia, en el mundo médico puede tener muchísimas causas, orígenes, factores de riesgo y variabilidades diarias.

Significancia del modelo (Estadístico F y p-valor):

El estadístico F mide la significancia global del modelo. En términos conceptuales, nos dice si la varianza explicada por el modelo (gracias a la variable independiente promedio_sistolica) es significativamente mayor que la varianza residual (o el "ruido" que no puede ser explicado por el modelo).

F se calcula a partir de la relación entre la varianza explicada (Suma de cuadrados explicada, asociada con la variabilidad capturada por el modelo) y la varianza residual (Suma de cuadrados residual, asociada con la variabilidad no explicada por el modelo).

Si el valor de F es alto, implica que la varianza explicada es considerablemente mayor que la varianza residual, lo que sugiere que el modelo es significativo. "Alto" es algo que por lo general es relativo entre una cosa y otra, así que lo que más nos va a interesar es el p -valor asociado al estadístico.

En este caso, el p -valor es muy bajo ($p<0.001$), lo que indica que el modelo en su conjunto es significativo. Esto implica que las variables son útiles para predecir promedio_sistolica con una confianza estadística alta, a pesar de la falta de explicación de variación.

Análisis de los coeficientes del modelo lineal:

Al ajustar un modelo lineal simple, lo que estamos ajustando son los valores de los coeficientes $\beta 0, \beta 1, \ldots, \beta n$.

El coeficiente de bhch04 es 8.4166, lo que significa que por cada unidad que incrementemos el año, el valor medio de la presión sistólica aumenta en esa proporción. Este coeficiente también es muy significativo ($p < 0.001$), lo que confirma la fuerte asociación entre ambas variables.

bima10 también es un predictor con peso alto, con un coeficiente de 5.3956.

bima07 posee un coeficiente negativo de -3,7563. Esto significa que por cada unidad que incrementemos el promedio. Mirando el p-valor no parece contribuir demasiado, por lo que a lo mejor podría eliminarse del modelo.

Por último provedio_fv_diario posee un coeficiente negativo de -0.2945. Tiene significancia muy baja ya que el p-valor es 0.043, pero no es la suficiente como para decir que es recomendable eliminarse del modelo.

La constante es 130.5595, lo que representa el valor medio estimado de la presión cuando la edad es cero. Aunque en un contexto real este valor no tenga un significado directo (Porque una edad de cero es irreal), ayuda a ajustar la línea de regresión.

El análisis de estos coeficientes es justamente el valor principal que tiene la regresión usada en este contexto. Pero no podemos asumirlos como verídicos hasta tanto no validemos el supuesto de normalidad de los residuos.

Supuesto de normalidad de los residuos

La normalidad de los residuos es un supuesto clave en el análisis de regresión, ya que afecta la validez de las inferencias realizadas. Utilizamos 2 maneras para revisarlos, primero analizamos los estadísticos obtenidos del comando summary (Test de Ómnibus y de Jarque-Bera) y la segunda de manera gráfica representando los residuos mediante un QQ-Plot.

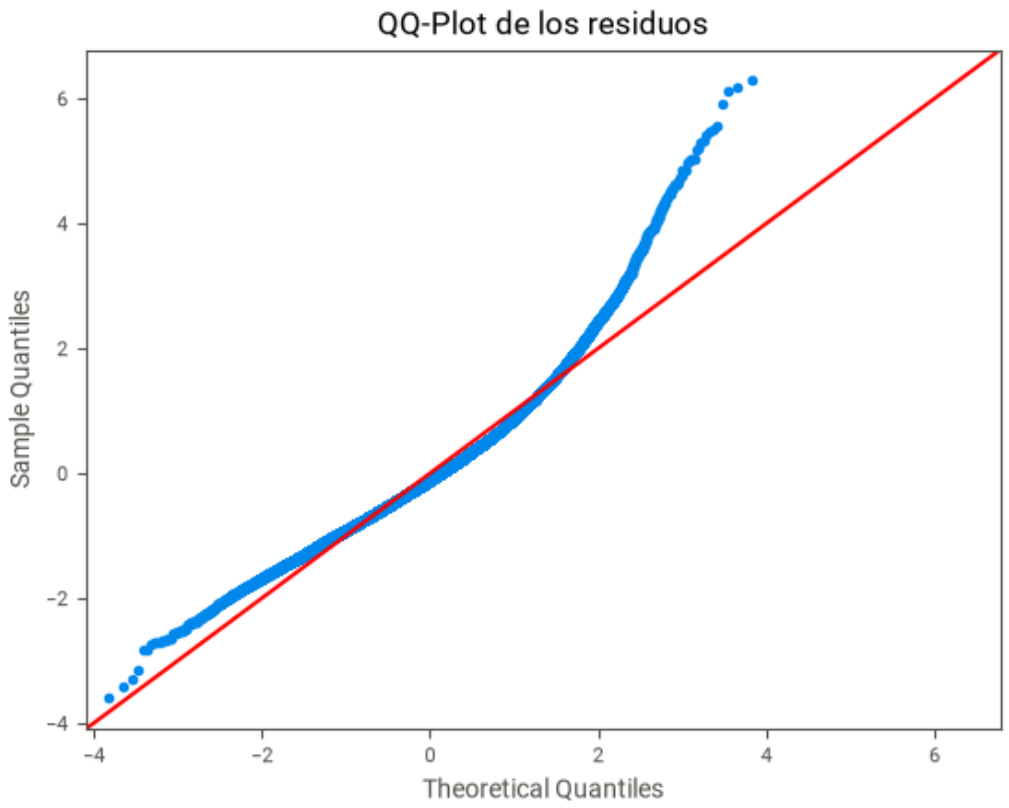


Fig. 6: QQ-Plot de los residuos del modelo. Los puntos se alejan de la diagonal, sobre todo en la cola superior, lo que indica que los residuos no siguen una distribución normal.

No tenemos una semejanza a la recta de la diagonal, por lo que todo parece indicar que los residuos no respetan una distribución normal. A continuación chequeamos los test provistos por summary.

Omnibus:	2539.454	Durbin-Watson:	1.976
Prob(Omnibus):	0.000	Jarque-Bera (JB):	5879.980
Skew:	0.936	Prob(JB):	0.00
Kurtosis:	5.350	Cond. No.	1.74

Fig. 7: Estadísticos de normalidad e independencia de los residuos del modelo. Los tests de Omnibus (2539,454) y Jarque-Bera (5879,980) tienen p=0,000, con asimetría de 0,936 y curtosis de 5,350, por lo que se rechaza la normalidad. El Durbin Watson (1,976) no indica autocorrelación.

El test de omnibus y el test de Jarque-Bera combinan dos aspectos estadísticos de los datos:

Asimetría (skewness): Indica si los residuales tienden a estar más hacia un lado (derecha o izquierda) de la distribución.

Curtosis: Mide si los datos tienen "colas" más pesadas o ligeras que una distribución normal.

El estadístico Omnibus analiza si hay desviaciones significativas en la asimetría y curtosis con respecto a la normalidad. Un p -valor bajo ($p<0.05$) sugiere que los residuos no son normales. El test de Jarque-Bera también estudia la asimetría y la curtosis, pero usa una metodología diferente. En nuestro caso podemos ver que ambos son bajos, por lo tanto indican que los residuales no siguen una distribución normal. Esto afecta directamente la validez de las afirmaciones anteriores.

Otra forma de estudiar la validez del modelo es representado gráficamente los valores ajustados por el modelo vs. los residuos. Deberíamos observar un comportamiento "en banda" alrededor del 0, sin demasiados errores por encima o debajo del 3 y el -3, respectivamente (porque en una normal estándar los valores por fuera del intervalo [-3, 3] son muy poco frecuentes).

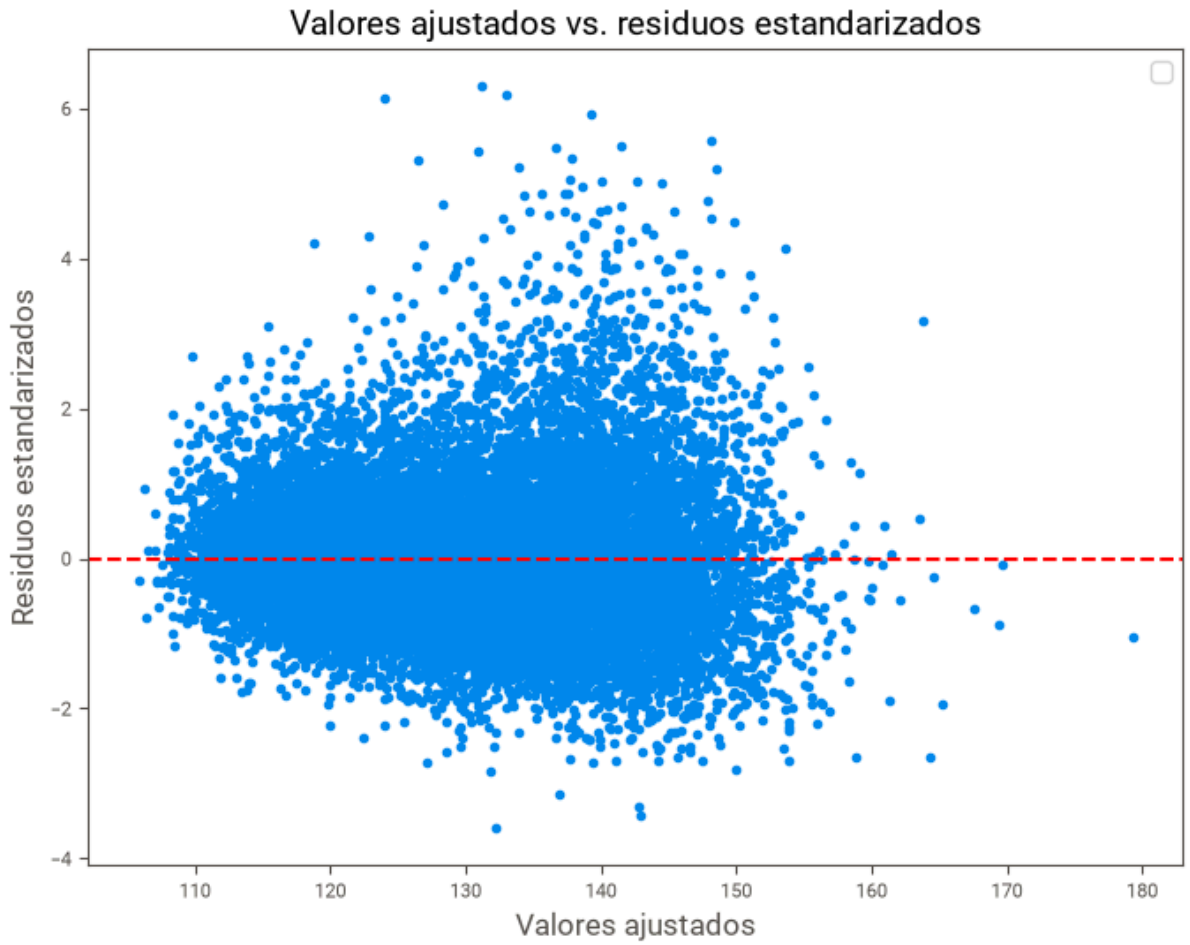


Fig. 8: Valores ajustados vs. residuos estandarizados del modelo. Los residuos no forman una banda pareja alrededor de 0: son más dispersos hacia arriba y varios superan los 3 desvíos estándar.

Vemos claramente que ese comportamiento en banda no existe.

Autocorrelación de los residuos y estadístico de Durbin-Watson

La autocorrelación de los residuales ocurre cuando los errores de una observación están correlacionados con los errores de otras observaciones cercanas, lo cual puede ser problemático. Este fenómeno es común en datos de series temporales o datos espaciales, donde las observaciones están naturalmente ordenadas o relacionadas.

El estadístico de Durbin Watson mide la presencia de autocorrelación en los residuos de un modelo de regresión. Su rango es entre 0 y 4, y podemos interpretarlo más o menos así:

Un valor cercano a 2 indica que no hay autocorrelación significativa.

Valores menores a 2 sugieren autocorrelación positiva (los errores tienden a estar relacionados de forma similar).

Valores mayores a 2 sugieren autocorrelación negativa (los errores alternan en signo entre observaciones).



Fig. 9: Estadístico de Durbin-Watson del modelo (1,976). Al estar cerca de 2, no hay autocorrelación significativa y los errores se pueden considerar independientes.

En este caso un valor de 1.976 indica que no hay autocorrelación significativa, lo cual puede fuertemente implicar que los errores son independientes entre sí.

Conclusión

Logramos sacar varias conclusiones hasta el momento de analizar los supuestos. La violacion de supuestos nos obliga a descartar el uso de bhch04, bima10, bima07 y promedio_fv_diario como predictores de promedio_sistolica.

3.6. Hipótesis Multivariada(Catedra) 2:

3.6.1. Definición de la hipótesis

Se plantea que existe una relación lineal entre el índice de masa corporal (imc_bima) y la presión sistólica (promedio_sistolica), el perímetro de la cintura (bima13), la edad (bhch04) y la glucemia capilar en ayunas (bimq05).

- Modelo

$$IMC_i = \beta_0 + \beta_1 Presion_i + \beta_2 Perimetro_i + \beta_3 Edad_i + \beta_4 Glucemia_i + \varepsilon_i$$

- Hipótesis estadísticas

$$H_0: \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0 \quad H_1: \text{al menos un } \beta_j \neq 0$$

3.6.2. Estrategia de abordaje

Para validar esta hipótesis se siguió una metodología en cuatro etapas:

1. Preparación de los datos: Se seleccionaron los encuestados con datos válidos en las cinco variables (N=5.039). Se separó la variable objetivo (imc_bima) de las predictoras y se estandarizaron estas últimas.
2. Ajuste del modelo: Se ajustó una regresión lineal múltiple por mínimos cuadrados y se analizó el summary(): R^2, estadístico F y coeficientes.
3. Verificación de supuestos: Se evaluó la normalidad de los residuos con un QQ-Plot y los tests de Omnibus y Jarque-Bera. Se evaluó la homocedasticidad con el gráfico de valores ajustados vs. residuos, y la independencia de los errores con el estadístico de Durbin Watson.
4. Conclusión: Se interpretaron los resultados teniendo en cuenta si los supuestos se cumplen.

3.6.3. Resultados obtenidos y discusión

OLS Regression Results

Dep. Variable:	imc_bima	R-squared:	0.647
Model:	OLS	Adj. R-squared:	0.647
Method:	Least Squares	F-statistic:	2305.
Date:	Sun, 08 Nov 2026	Prob (F-statistic):	0.00
Time:	19:49:42	Log-Likelihood:	-13438.
No. Observations:	5039	AIC:	2.689e+04
Df Residuals:	5034	BIC:	2.692e+04
Df Model:	4		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	28.1912	0.049	574.303	0.000	28.095	28.287
promedio_sistolica	0.3408	0.057	5.998	0.000	0.229	0.452
bima13	4.6633	0.054	86.317	0.000	4.557	4.769
bhch04	-0.3242	0.056	-5.782	0.000	-0.434	-0.214
bimq05	0.0843	0.050	1.669	0.095	-0.015	0.183

Omnibus:	541.107	Durbin-Watson:	1.919
Prob(Omnibus):	0.000	Jarque-Bera (JB):	2863.057
Skew:	0.380	Prob(JB):	0.00
Kurtosis:	6.614	Cond. No.	1.84

Fig. 10: Resumen (summary) del modelo de regresión lineal múltiple del IMC (imc_bbima) según presión sistólica, perímetro de cintura, edad y glucemia, con N=5.039. El R^2 es 0,647 y el modelo es significativo en conjunto (F=2305, p<0,001). El perímetro de cintura es el coeficiente más influyente (4,66). La glucemia no es significativa (p=0,095).

Explicación del summary:

R2:

En nuestro caso, vemos que obtuvimos un R2 de 0.647. Esto indica que el modelo explica aproximadamente el 64.7% de la varianza de imc_bima a partir de promedio_sistolica, bima13, bhch04 y bimq05. Esto sugiere que estos predictores funcionan correctamente (Podría ser mejor). Cabe destacar que aún falta varianza sin explicar, posiblemente por las mismas razones mencionadas en la hipótesis formulada anteriormente.

Significancia del modelo (Estadístico F y p-valor):

En este caso, el p -valor es muy bajo ($p<0.001$), lo que indica que el modelo en su conjunto es significativo e implica lo mismo que en el modelo anterior.

Análisis de los coeficientes del modelo lineal:

El coeficiente de bima13 es 4.6633, lo que significa que por cada unidad que incrementemos el perímetro de cintura, el valor medio de imc aumenta en esa proporción.

promedio_sistolica tiene un coeficiente de 0.3408, no tiene un peso muy grande.

bhch04 posee un coeficiente negativo de -0.3242. Esto significa que por cada unidad que incrementemos el promedio. Mirando el p-valor no parece contribuir demasiado, por lo que a lo mejor podría eliminarse del modelo.

Por último bimq05 posee un coeficiente de 0.0843 lo que indica una contribucion muy baja en el modelo. Tiene significancia muy baja ya que el p-valor es 0.095, se podria sacar del modelo.

La constante es 28.1912, lo que representa el valor medio estimado del imc cuando el promedio de la cintura es cero. Sigue sin tener significado en un contexto real pero ayuda a ajustar la línea de regresión.

Supuesto de normalidad de los residuos

Analizamos nuevamente los estadísticos obtenidos del comando summary (Test de Ómnibus y de Jarque-Bera) y representamos los residuos mediante un QQ-Plot.

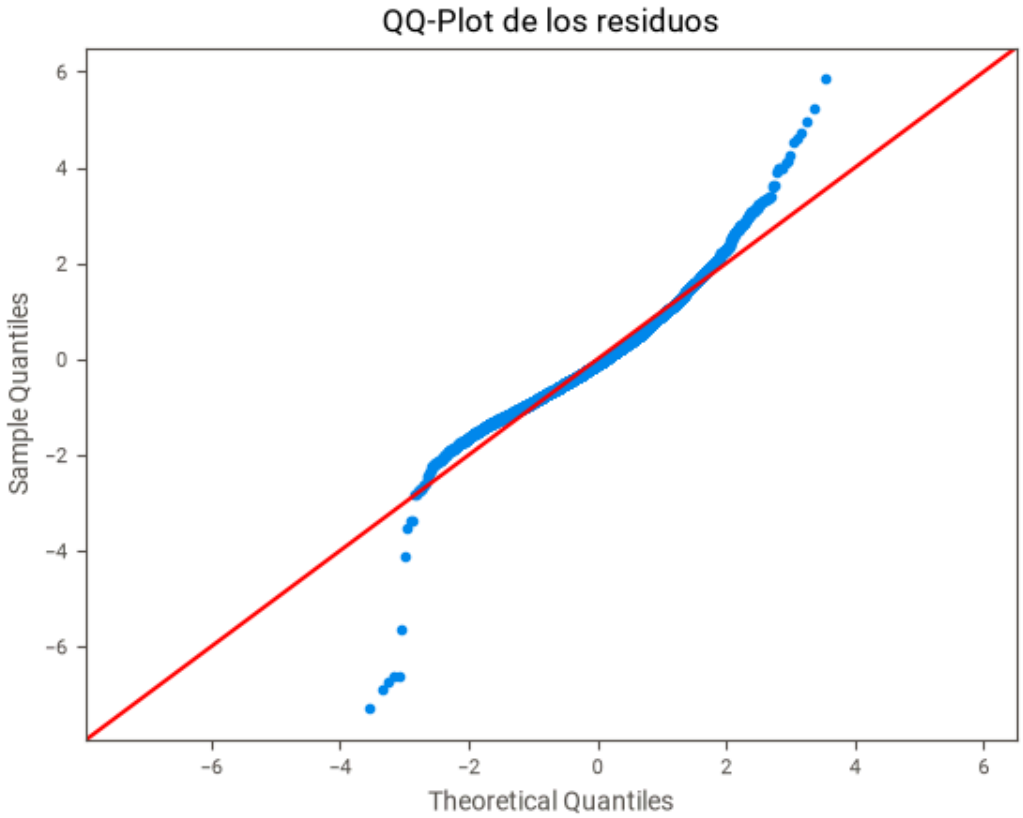


Fig. 11: QQ-Plot de los residuos del modelo. Los puntos se alejan de la diagonal en ambas colas, sobre todo en la inferior, lo que indica que los residuos no siguen una distribución normal.

No tenemos una semejanza a la recta de la diagonal, por lo que todo parece indicar que los residuos no respetan una distribución normal. A continuación chequeamos los test provistos por summary.

Omnibus:	541.107	Durbin-Watson:	1.919
Prob(Omnibus):	0.000	Jarque-Bera (JB):	2863.057
Skew:	0.380	Prob(JB):	0.00
Kurtosis:	6.614	Cond. No.	1.84

Fig. 12: Estadísticos de normalidad e independencia de los residuos del modelo. Los tests de Omnibus (541,107) y Jarque-Bera (2863,057) tienen p=0,000, con asimetría de 0,380 y curtosis de 6,614, por lo que se rechaza la normalidad. El Durbin Watson (1,919) no indica autocorrelación.

Podemos ver que ambos son bajos, por lo tanto indican que los residuales no siguen una distribución normal. Esto afecta directamente la validez de las afirmaciones anteriores.

Representamos los valores ajustados por el modelo vs. los residuos.

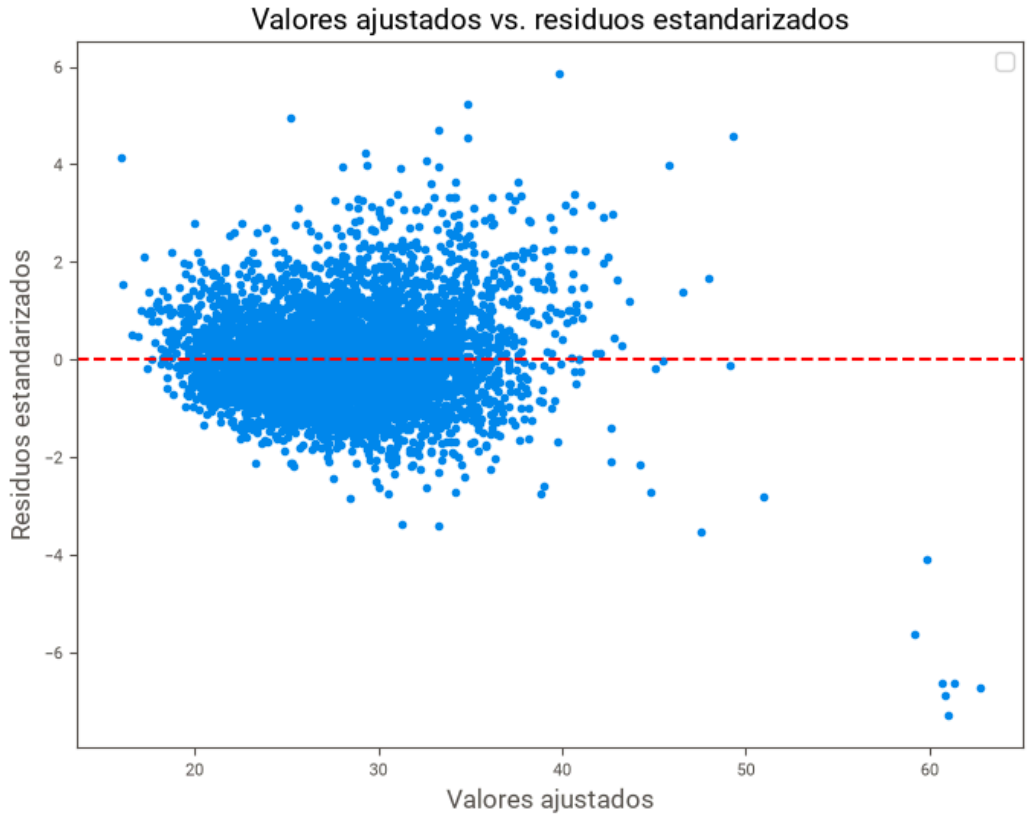


Fig. 13: Valores ajustados vs. residuos estandarizados del modelo. Los residuos no forman una banda pareja alrededor de 0: hay varios puntos por encima de 4 y un grupo de observaciones con valores ajustados altos (cerca de 60) y residuos de entre −6 y −7, que se alejan del resto.

Vemos claramente que ese comportamiento en banda no existe.

Autocorrelación de los residuos y estadístico de Durbin-Watson

Medimos el estadistico de Durbin Watson.



Fig. 14: Estadístico de Durbin-Watson del modelo (1,919). Al estar cerca de 2, no hay autocorrelación significativa y los errores se pueden considerar independientes.

En este caso un valor de 1.919 indica que no hay autocorrelación significativa, lo cual puede fuertemente implicar que los errores son independientes entre sí.

Conclusión

Sucede lo mismo que en la hipótesis anterior ya que, a pesar de haber logrado sacar varias conclusiones hasta el momento, la violacion de supuestos nos obliga a descartar el uso de todas las variables como predictoras del índice de masa corporal (imc_bima).

4. Conclusiones

Este trabajo analizó la ENFR 2018 con foco en alimentación y nutrición, y planteó seis hipótesis cuyos resultados se resumen a continuación.

En las hipótesis univariadas, el 63,59% de las personas declara no agregar nunca sal a la comida en la mesa, por lo que se rechazó que esa proporción sea del 50% o menos (3.1). El consumo de frutas y verduras es muy bajo: la mediana es de 1,64 porciones y la media de 2,07, significativamente menor a las 5 porciones recomendadas por la OMS (3.2).

En las hipótesis bivariadas, el consumo de frutas y verduras aumenta con el nivel de ingresos del hogar: el promedio pasa de 1,71 porciones en el quintil 1 a 2,43 en el quintil 5, y el porcentaje de personas que alcanza las 5 porciones sube de 3,86% a 8,75% (3.3). El IMC también cambia según el nivel de actividad física, y es mayor cuanto menor es esa actividad, con medianas de cerca de 26, 27 y 28 en los niveles alto, medio y bajo (3.4). En ambos casos la diferencia fue significativa con pruebas no paramétricas, porque no se cumplieron los supuestos de normalidad ni de igualdad de varianzas.

En las hipótesis multivariadas, el modelo que explica la presión sistólica a partir de la edad, el peso, la talla y el consumo de frutas y verduras alcanzó un R^2 de 0,245 (3.5), y el que explica el IMC a partir de la presión sistólica, la cintura, la edad y la glucemia alcanzó un R^2 de 0,647 (3.6). En este último, el perímetro de la cintura es el predictor con mayor peso. Los residuos de ambos modelos no siguen una distribución normal y no presentan el comportamiento en banda esperado, por lo que los resultados deben interpretarse con cautela, y el poder explicativo del primer modelo es limitado: la presión arterial depende de muchos factores que la encuesta no mide.

Las mediciones físicas faltan en cerca del 44% de los registros y la glucemia en el 82% por el diseño de la encuesta, y se trabajó solo con los casos completos de cada hipótesis. Además, el consumo de frutas, verduras y sal es autorreportado, y las asociaciones encontradas no implican causalidad.

Los resultados describen un patrón consistente: bajo consumo de frutas y verduras, mayor en los hogares de más ingresos, y mayor IMC en quienes hacen menos actividad física.

Referencias

1. Instituto Nacional de Estadística y Censos (INDEC). (2019). 4.ª Encuesta Nacional de Factores de Riesgo: Manual de uso de la base de datos usuario. https://www.indec.gob.ar/ftp/cuadros/menusuperior/enfr/manual_base_usuario_enfr2018.pdf
2. Instituto Nacional de Estadística y Censos (INDEC). (2019). Encuesta Nacional de Factores de Riesgo 2018: Cuestionario. https://www.indec.gob.ar/ftp/cuadros/sociedad/cuestionario_enfr_2018.pdf